

金策 FinSight MVP 评测方案（H）

当前状态：金策 FinSight 处于方案设计 + 产品原型阶段，未开发完成、未上线。本文件记录拟执行的 MVP 对照实验。表中数值均为 **MVP目标**，不是实测结果；实验完成前不得作为项目成果引用。正式实验将保留原始输出、失败记录和负结果，以实测值填写结果列。

1. 问题定义与实验假设

本轮评测回答以下问题：在基础模型、可用语料、任务集和提示词优化投入尽量一致的条件下，引入多智能体分工、结构化证据链、确定性组合计算和流程内合规检查，是否比普通单模型或单模型 + RAG 更可靠；相应的时间与模型调用成本是否仍处于 MVP 可用范围。

预注册的主要比较为 C 组对 B 组，其次为 C 组对 A 组。核心观察指标为事实准确率、引用支持率、无依据结论比例、组合计算准确率和合规风险识别召回率。报告生成时间、模型成本、系统延迟和失败率用于判断工程代价，不以牺牲事实或合规指标换取速度。

待检验假设：

- H1：结构化证据链可提高引用覆盖率和引用支持率，并降低无依据结论比例。
- H2：多角色生成与审核回路可提高事实准确率，但可能增加延迟和模型成本。
- H3：组合计算交由确定性程序并采用独立重算，可减少数值和口径错误。
- H4：合规检查嵌入输出流程后，对预埋风险点的召回率高于不设合规模块的基线。

2. 对照组与控制变量

组	配置	用途
A	普通单模型	单一通用大模型直接完成任务；不接检索、不生成结构化证据链、不调用合规模块
B	单模型 + RAG	与 C 组使用同一基础模型和同一时点语料；提供向量检索，不设置多智能体分工、证据链字段约束和独立合规审查
C	金策方案	多智能体投研流程 + 结构化证据链 + 因果与情景字段 + 组合计算 + 合规检查；当前为拟实现和待验证配置

控制变量包括基础模型版本、温度、任务集、语料快照、任务截止时点和最大上下文预算。A/B 组提示词允许同等轮次优化，避免用弱提示词制造基线差距。B/C 组共用检索语料和数据更新时间；如果某项能力只能在 C 组使用，实验记录中单列该差异，不将其伪装为模型能力差异。

3. 数据集构成

3.1 任务集

MVP 任务集计划不少于 30 个任务，每类不少于 10 个：

类别	任务内容	主要评分对象
宏观事件类	利率、通胀、就业等公开事件的事实核查、传导链和三情景推演	事实、时效、引用、假设与反方情景
公司基本面类	基于公开财报、公告分析指标变化或重大事项影响	数字、单位、会计口径、原文定位

类别	任务内容	主要评分对象
组合与合规类	使用明确标注的模拟持仓进行集中度、敞口和压力测试；改写含预埋合规风险的客户材料	确定性计算、适当性、收益承诺、风险提示和 AI 标识

每个任务包含任务截止时点、允许使用的语料快照、标准答案要点、必须引用的陈述点、可接受的推断范围和评分细则。测试集中预埋过期数据、相近指标口径、单位换算、相关性与因果混淆、证据与结论不匹配等错误触发点。

3.2 数据来源与难度校准

只使用公开信息和明确授权数据，包括央行公告、交易所公告、上市公司公开披露与公开新闻；不使用未经授权的付费数据或研报。每条语料登记来源、发布时间、更新时间、抓取时间、授权状态和任务截止时点。

公开基准 FinanceBench (arXiv:2311.11944) 报告，GPT-4-Turbo + RAG 配置下金融问答约 81% 的回答答错或拒答。该结果仅用于说明金融问答的难度和构造错误类型，不作为本项目成绩，也不直接推定本任务集上的基线得分。正式实验前将选取同类题型做小规模难度校准；校准任务不进入正式计分集。

3.3 标准答案与盲法

标准答案由公开原文、结构化数据重算结果和合规风险点清单组成。程序化答案与人工 rubric 在实验前冻结。人工评审至少 2 人，隐藏组别并随机化输出顺序；同一任务的三组答案避免连续展示，以降低锚定效应。

4. 打分规则

4.1 指标定义

指标	计分单位	计算规则
事实准确率	事实陈述	正确事实数 / 事实陈述总数；程序比对后抽样 20% 双盲复核
数字准确率	数值字段	数值、单位和口径均正确的字段数 / 数字字段总数；因来源更新产生的容差上限为 $\pm 0.5\%$ ，并单独标记
引用覆盖率	应引用陈述点	带有效证据编号的陈述点数 / 应引用陈述点总数
引用支持率	已给引用	$(支持 + 0.5 \times 部分支持) / 抽样引用数$ ；抽样比例 30%，且不少于 50 条
无依据结论比例	结论性陈述	无证据且未显式标注假设的结论数 / 结论总数，越低越好
信息时效性	证据条目	截至任务时点仍有效的证据数 / 证据总数；另计时间戳字段完整率
组合计算准确率	计算项	与独立重算脚本一致的计算项数 / 计算项总数，仅允许预先定义的四舍五入差异
合规风险识别	预埋风险点、系统命中	召回率 = 检出风险点 / 预埋风险点；精确率 = 真实风险命中 / 全部命中
报告生成时间	单任务	从提交到形成可送人工确认草稿的墙钟时间，按任务类型报告 P50/P95
资料整理与重复核验耗时	单任务、研究员	从开始收集材料到完成可供分析的资料包与首轮数字核对的墙钟时间；A/B/C组三组使用相同任务和截止时间

指标	计分单位	计算规则
用户任务完成率	用户任务	无需系统外补救而独立完成任务数 / 用户任务总数
模型成本	单任务	全部模型调用 token × 实验时单价，包含 repair 和失败调用
系统延迟	请求、流程阶段	首字节延迟及阶段流转延迟的 P50/P95，由 trace 时间戳计算
失败率	单任务	因编排、检索、格式或超时错误未产出可评审结果的任务数 / 总任务数
用户满意度	受试者问卷	SUS 量表 0—100；另记录证据可追溯性、表达清晰度、合规放心度 5 点题

4.2 MVP 目标表

以下目标用于决定是否进入下一轮工程迭代，不代表当前已达到。正式报告增加“实测值、置信区间、是否达到目标”三列。

指标	MVP目标
事实准确率	≥ 95%
数字准确率	≥ 98%
引用覆盖率	≥ 95%
引用支持率	≥ 90%
无依据结论比例	≤ 5%
信息时效性	时效合格率 ≥ 95%；时间戳字段完整率 = 100%
组合计算准确率	= 100%
合规风险识别	召回率 ≥ 90%；精确率 ≥ 85%
报告生成时间	单事件任务 P50 ≤ 10 分钟；P95 ≤ 20 分钟
资料整理与重复核验耗时	较人工基线压缩 ≥ 50%
用户任务完成率	≥ 85%
模型成本	单任务 ≤ 10 元人民币等值，按实验时实际单价折算
系统延迟	首字节 P50 ≤ 5 秒；单阶段流转 P95 ≤ 60 秒
失败率	≤ 5%，且失败原因可由日志定位
用户满意度	SUS ≥ 75；3 个领域题均分 ≥ 4.0/5

4.3 判定细则

- 事实陈述、推断、情景假设和风险提示先由标注员分类；分类有争议时先仲裁，再计算分母。
- 引用必须能定位到具体原文或结构化字段。只列来源名称而不能定位内容，不计为有效引用。
- “部分支持”仅用于原文支持方向但不支持强度、范围或时间限定的情况；与结论无关或方向相反记为“不支持”。
- 组合计算采用两套独立实现生成和复核标准值。两套脚本不一致时，该题暂停计分并排查基准，而不是选择对 C 组有利的答案。
- 任务失败保留原始记录。只允许按预注册规则重试，首次结果与重试结果分别报告。

- 用户测试计划招募 5–8 名具金融背景的受试者。该样本量只用于发现可用性问题，不用于宣称广泛用户效果。

5. 误差来源与控制

误差来源	可能影响	控制或披露方式
语料在实验期间更新	数字和事实答案发生漂移	冻结语料快照；保留发布时间、更新时间和抓取时间
标准答案不完整	正确但未收录的答案被误判	设置“可接受替代答案”；争议项人工仲裁并记录修改原因
评审主观差异	推断质量、引用支持判断不一致	双盲双评；以 Cohen's κ 报告一致性； $\kappa < 0.6$ 的维度重评
基线提示词质量不等	夸大 C 组增益	统一提示词优化轮次和上下文预算，公开三组最终提示词版本
模型服务波动	延迟、失败率和成本偏移	同时段交错运行三组；记录服务商错误和限流，不归因于架构能力
检索命中差异	把数据可得性误当作推理能力	B/C 共用语料、索引快照和检索上限；分别报告检索召回
任务泄漏或人工熟悉	得分虚高	正式集与调试集隔离；冻结后不用于提示词调试
小样本和多重比较	偶然显著或功效不足	事前功效估算；Holm–Bonferroni 校正；功效不足标为探索性结果
用户角色扮演偏差	完成率与真实机构流程不一致	记录受试者背景、任务脚本和观察笔记，不外推到生产效果

6. 数据采集与统计分析

系统侧计划自动采集 runs/run_steps、token 用量、阶段时间戳、失败堆栈、检索命中、合规检查和人工确认记录；这些字段是 MVP 拟实现的评测埋点。现有先导项目 Mindraft AI Gateway 已具备四阶段 Pipeline、SSE trace 和 runs/run_steps 落库能力，但这不等同于金策评测管线已经完成。

程序化校验结果结构化入库，人工评分保留两名评审的原始分和仲裁记录。用户侧保存任务观察记录及 SUS/李克特问卷，受试者签署知情同意，问卷匿名化存储。

统计方法预先冻结：

- 比例类指标使用卡方检验；预期频数不足时使用 Fisher 精确检验，并报告 Wilson 95% 置信区间。
- 连续类指标先检查分布；正态数据使用独立样本 t 检验，非正态数据使用 Mann–Whitney U，并报告 Cohen's d 或 rank–biserial 效应量。
- 核心指标族采用 Holm–Bonferroni 校正。除 p 值外，同时报告绝对差、相对差、置信区间和失败样本。
- 30 个任务是 MVP 可行性规模。事前功效估算若显示无法检验预期差异，结果只作探索性描述，不写成验证成功。

7. 伦理与合规边界

- 所有客户画像与持仓使用模拟数据，不涉及真实客户信息。
- 输出仅用于研究流程测试，统一标注“非投资建议”，不自动荐股，不替客户决策。
- 受试者知情同意并可退出；问卷和操作记录按最小必要原则采集。

- 评测参照《生成式人工智能服务管理暂行办法》（国家网信办等七部门令第15号）、《证券期货投资者适当性管理办法》（证监会令第130号）、《证券投资基金经营机构信息技术管理办法》（证监会令第152号）、《证券期货业网络和信息安全管理暂行办法》（证监会令第218号）。
- 实验失败、负结果、人工分歧和成本超支均保留，不删除不利样本。

8. 执行顺序与交付物

1. 冻结任务集、语料快照、标准答案、评分细则和预注册文档。
2. 搭建三组环境并各运行 3 个不计分的冒烟任务，修复基础设施问题。
3. 交错运行正式任务，记录首次输出、允许的重试和全部失败。
4. 完成程序化校验、双盲人工评审及一致性仲裁。
5. 运行统计分析，形成含目标值、实测值、置信区间、负结果和误差说明的报告。
6. 在系统可用后执行 5—8 人可用性测试，单独报告观察结论，不与模型效果混合解释。